

Εργασία Βαθιά Μάθηση και Ανάλυση Πολυμεσικών Δεδομένων

Βαθιά Συνελκτικά Νευρωνικά Δίκτυα και Βαθιά Αναδρομικά Νευρωνικά Δίκτυα

Ημερομηνία: 13/05/2025

Δήμος Δημήτριος Πλακωτάρης ΑΕΜ:180

Κώδικας (git repo): https://github.com/dp-ops/Image_captioning

Εισαγωγή

Στην εργασία αυτή υλοποιεί ένα μοντέλο λεζάντας εικόνων βασισμένο στη βαθιά μάθηση, το οποίο παράγει περιγραφές φυσικής γλώσσας για εικόνες. Η αρχιτεκτονική του μοντέλου συνδυάζει συνελκτικά νευρωνικά δίκτυα (CNN) για την εξαγωγή χαρακτηριστικών με επαναλαμβανόμενα νευρωνικά δίκτυα (RNN) και έναν μηχανισμό προσοχής (Attention network) για τη διαδοχική παραγωγή λεζάντας.

Στον πυρήνα του μοντέλου, αποτελείτε από τρία διαφορετικά δίκτυα. Το ResNet34, ένα βαθύ συνελκτικό δίκτυο, χρησιμοποιείται ως κωδικοποιητής εικόνας. Προεκπαιδευμένο στο ImageNet, εξάγει αποτελεσματικά οπτικά χαρακτηριστικά υψηλού επιπέδου από τις εικόνες εισόδου. Τα εξαγόμενα χαρακτηριστικά εικόνας περνάνε στη συνέχεια σε ένα δίκτυο LSTM (Long Short-Term Memory), το οποίο λειτουργεί ως αποκωδικοποιητής, δημιουργώντας λεζάντες λέξη προς λέξη. Ένας ολοκληρωμένος μηχανισμός προσοχής εστιάζει δυναμικά σε διαφορετικά μέρη της εικόνας κατά τη διάρκεια κάθε βήματος της διαδικασίας παραγωγής λεζάντας, επιτρέποντας στο μοντέλο να παράγει λεζάντες σχετικές με το πλαίσιο και περιγραφικές.

Αυτός ο συνδυασμός ResNet34 + LSTM + Attention επιτρέπει στο μοντέλο να χειρίζεται τόσο την οπτική κατανόηση όσο και τη διαδοχική παραγωγή κειμένου, καθιστώντας το ικανό να παράγει συνεκτικές και ουσιαστικές περιγραφές για διαφορετικές εικόνες, συνδυάζοντας κάπως έτσι τα δύο από τα τρία μεγάλα θέματα για την εργασία του εξαμήνου.

Το μοντέλο εκπαιδεύτηκε σε δύο γνωστά για παρόμοιες εφαρμογές σύνολα δεδομένων, το ένα συνέχεια του άλλου, με ευρέα ποικιλία από διαφορετικές εικόνες και τις διαθέσιμες λεζάντες τους. Συγκεκριμένα τα Flickr8k και Flickr30k, τα οποία θα αναλυθούν περεταίρω μέσα στην εργασία.

Τέλος, έγινε και προσπάθεια εφαρμογής βαθιάς ενισχυτικής μάθησης στο μοντέλο, ωστόσο επειδή τα αποτελέσματα της δεν είναι αξιόλογα, θα αφιερωθεί νέα εργασία μόνο σε αυτό το θέμα.

Στον σύνδεσμο του κώδικα διαθέσιμου στην αρχή του εγγράφου αυτού, υπάρχουν όλα τα σκριπς που χρησιμοποιήθηκαν για την προετοιμασία των δεδομένων, την εκπαίδευση, των έλεγχο και την εξαγωγή των συμπερασμάτων από την παρούσα εφαρμογή καθώς και οδηγίες για το πως αυτά μπορούν αν υλοποιηθούν από το μηδέν.

Υλικά και Μέθοδοι

Σετ δεδομένων

Το σύνολο δεδομένων Flickr8k είναι ένα ευρέως χρησιμοποιούμενο μέτρο σύγκρισης για εργασίες λεζάντας εικόνων, το οποίο περιέχει 8.000 εικόνες που συλλέχθηκαν από το Flickr, καθεμία από τις οποίες σχολιάστηκε με πέντε περιγραφικές λεζάντες. Αυτές οι λεζάντες δημιουργήθηκαν από ανθρώπινους σχολιαστές, παρέχοντας φυσικές και ποικίλες περιγραφές για κάθε εικόνα. Το σύνολο δεδομένων καλύπτει ένα ευρύ φάσμα καθημερινών σκηνών, αντικειμένων και ανθρώπινων δραστηριοτήτων, καθιστώντας το κατάλληλο για την εκπαίδευση και την αξιολόγηση μοντέλων σε εργασίες παραγωγής εικόνων σε κείμενο σε περιορισμένα περιβάλλοντα.

Μια επέκταση αυτού του πόρου, το σύνολο δεδομένων Flickr30k επεκτείνει σημαντικά τη συλλογή, περιλαμβάνοντας 30.000 εικόνες με πέντε λεζάντες η καθεμία. Σχεδιασμένο για να παρέχει ένα μεγαλύτερο και πιο ποικίλο σύνολο δεδομένων για την έρευνα στον τομέα των λεζάντων εικόνων και της πολυτροπικής μάθησης, το Flickr30k εισάγει μεγαλύτερη ποικιλομορφία τόσο στο οπτικό περιεχόμενο όσο και στις γλωσσικές εκφράσεις. Αυτό το σύνολο δεδομένων χρησιμεύει ως πολύτιμος πόρος για την ανάπτυξη και τη συγκριτική αξιολόγηση μοντέλων βαθιάς μάθησης που στοχεύουν στη γεφύρωση της οπτικής κατανόησης και της παραγωγής φυσικής γλώσσας.

Για την παρούσα εφαρμογή δόθηκε μεγαλύτερη βάση στο πρώτο σύνολο δεδομένων (Flickr8k) καθώς λόγω του μικρότερου μεγέθους του, δοκιμάστηκαν περισσότερα σενάρια εκπαίδευσης και των τα αποτελέσματα ήταν γρηγορότερα ορατά, προς αποφυγή λάθους και πόρων/χρόνου.

Προετοιμασία δεδομένων

Για την προετοιμασία του συνόλου δεδομένων Flickr8k για την εκπαίδευση του μοντέλου λεζάντας εικόνας, χρησιμοποιείται ένα custom script προεπεξεργασίας το `create_data_n_prep.py`. Αυτό το script εκτελεί διάφορα βασικά βήματα για τη μετατροπή των ακατέργαστων αρχείων εικόνων και των σχετικών λεζάντων τους σε μια δομημένη, έτοιμη για το μοντέλο μορφή.

Ο κώδικας ξεκινά με τη φόρτωση ενός αρχείου σχολίων JSON που περιέχει μεταδεδομένα εικόνων και τις αντίστοιχες λεζάντες τους. Με βάση τον διαχωρισμό που έχει οριστεί (train, val ή test), οι εικόνες και οι λεζάντες τους οργανώνονται σε αντίστοιχες λίστες για περαιτέρω επεξεργασία.

Ένα κρίσιμο βήμα περιλαμβάνει τη δημιουργία ενός vocabulary dictionary (word map) μετρώντας τις συχνότητες των λέξεων σε όλες τις λεζάντες. Οι λέξεις που εμφανίζονται λιγότερες φορές από

ένα καθορισμένο κατώφλι (`min_word_freq`) αποκλείονται για να περιοριστεί το μέγεθος του λεξιλογίου και να μειωθεί η πολυπλοκότητα του μοντέλου. Ειδικά tokens όπως `<start>`, `<end>`, `<pad>` και `<unk>` προστίθενται για τη διαχείριση της δημιουργίας ακολουθιών και άγνωστων λέξεων κατά την εκπαίδευση.

Για τα δεδομένα εικόνας, κάθε εικόνα διαβάζεται με τη χρήση του OpenCV, μετατρέπεται σε RGB και αλλάζει το μέγεθός της σε σταθερή διάσταση 256×256 pixel. Στη συνέχεια, οι εικόνες αποθηκεύονται σε ένα αρχείο HDF5, με διαστάσεις τυποποιημένες σε (3, 256, 256) κανάλια για συμβατότητα με τον κωδικοποιητή ResNet34.

Για τις λεζάντες, ο κώδικας εξασφαλίζει έναν σταθερό αριθμό λεζάντων ανά εικόνα (που ορίζεται από την `captions_per_image`). Εάν μια εικόνα έχει λιγότερες λεζάντες, οι υπάρχουσες διπλασιάζονται ενώ εάν είναι περισσότερες, λαμβάνεται ένα τυχαίο δείγμα. Στη συνέχεια, κάθε λεζάντα κωδικοποιείται σε αλληλουχίες ακεραίων αριθμών χρησιμοποιώντας τον χάρτη λέξεων που δημιουργήθηκε προηγουμένως, με τα σημεία `<start>` και `<end>` να προστίθενται για να σηματοδοτούν τα όρια των προτάσεων. Οι λεζάντες συμπληρώνονται σε ένα μέγιστο μήκος (`max_len`) και τόσο οι κωδικοποιημένες λεζάντες όσο και τα μήκη τους αποθηκεύονται σε αρχεία JSON.

Στο τέλος αυτής της διαδικασίας, το σύνολο δεδομένων Flickr8k είναι οργανωμένο σε αρχεία HDF5 για τις εικόνες και σε αρχεία JSON για τις λεζάντες, τα μήκη των λεζάντων και τον χάρτη λέξεων. Αυτή η δομημένη μορφή είναι απαραίτητη για την αποτελεσματική εκπαίδευση του μοντέλου λεζάντας εικόνας, διασφαλίζοντας ότι τόσο τα χαρακτηριστικά της εικόνας όσο και τα διαδοχικά δεδομένα κειμένου προετοιμάζονται με συνέπεια και προσοχή για το πλαίσιο κωδικοποιητή-αποκωδικοποιητή.

Μοντέλο

Βαθιά Συνελκτικά Νευρωνικά Δίκτυα (ResNet34)

Για το κομμάτι των βαθιών συνελκτικών νευρωνικών δικτύων κατασκευαστικό από το μηδέν ένα μια υλοποίηση της ResNet34 βασισμένη στο θεμελιώδες paper «Deep Residual Learning for Image Recognition» (He et al., 2015). Πρόκειται για ένα συνελκτικό νευρωνικό δίκτυο που έχει σχεδιαστεί για την εξαγωγή χαρακτηριστικών από εικόνες, παίζοντας το ρόλο του κωδικοποιητή στον αγωγό αναγνώρισης εικόνων.

Αυτή η υλοποίηση χρησιμοποιεί μπλοκ, τα οποία αποτελούνται από δύο επίπεδα συνελκτικής ανάλυσης με ομαλοποίηση batch και ενεργοποίηση ReLU. Μια σύνδεση παράκαμψης επιτρέπει στα χαρακτηριστικά εισόδου να παρακάμπτουν τα επίπεδα συνελκτικής επεξεργασίας, συμβάλλοντας απευθείας στην έξοδο. Αυτή η αρχιτεκτονική βοηθά στον μετριασμό του

προβλήματος των vanishing gradient, εξασφαλίζοντας την αποτελεσματική εκπαίδευση των βαθιών δικτύων.

Η κλάση ResNet αναπαριστά τον κωδικοποιητή, ακολουθώντας τη διαμόρφωση [3, 4, 6, 3] για τα επίπεδά της, η οποία αντιστοιχεί στην αρχιτεκτονική του ResNet34. Κάθε ομάδα layer αυξάνει προοδευτικά τον αριθμό των καναλιών μειώνοντας παράλληλα τις χωρικές διαστάσεις μέσω των strided convolutions. Το δίκτυο ξεκινά με μια αρχική συνέλιξη 7x7 που ακολουθείται από max pooling, η οποία μειώνει σημαντικά τη χωρική ανάλυση.

Σε αντίθεση με το αρχικό ResNet34, το οποίο περιλαμβάνει ένα global average pooling layer και ένα πλήρως συνδεδεμένο layer (FC) για ταξινόμηση, αυτή η υλοποίηση παραλείπει αυτά τα layers για το ρόλο της ως εξαγωγής χαρακτηριστικών. Η απουσία αυτών των layer διασφαλίζει ότι ο κωδικοποιητής παράγει χάρτες χαρακτηριστικών υψηλής διάστασης κατάλληλους για μεταγενέστερες εργασίες όπως η λεζάντα εικόνας με βάση την προσοχή.

Η έξοδος αυτού του κωδικοποιητή είναι ένας τανυστής σχήματος (batch_size, 512, h/32, w/32), όπου h και w είναι οι διαστάσεις της εικόνας εισόδου. Αυτός ο τανυστής επεξεργάζεται περαιτέρω με adaptive average pooling σε σταθερή χωρική ανάλυση (π.χ. 14x14) και η τελική κωδικοποίηση αναδιαμορφώνεται σε (batch_size, num_pixels, 512) για συμβατότητα με τον μηχανισμό προσοχής στον αποκωδικοποιητή.

Για την διευκόλυνση της εκπαίδευσης του EncoderCNN, χρησιμοποιήθηκαν τα προεκαιδευμένα βάρη για τον ResNet34 στην ImageNet μέσω της βιβλιοθήκης torchvision και πάνω σε αυτά έγινε fine-tune για το πρόβλημα της δημιουργίας λεζάντας.

Μηχανισμός Προσοχής (Attention network)

Ο μηχανισμός προσοχής που υλοποιήθηκε σε αυτή την εργασία αποτελεί βασικό στοιχείο του μοντέλου. Επιτρέπει στο μοντέλο να εστιάζει δυναμικά σε συγκεκριμένες περιοχές της εικόνας που είναι πιο σχετικές για την παραγωγή κάθε λέξης στη λεζάντα. Η αρχιτεκτονική του μηχανισμού προσοχής έχει υλοποιηθεί ως αυτόνομη ενότητα στον κώδικα και δέχεται δύο κύριες εισόδους: τις χωρικές εξόδους του ResNet34 encoder και την κρυφή κατάσταση του αποκωδικοποιητή LSTM σε κάθε χρονικό βήμα. Οι πληροφορίες αυτές συνδυάζονται ώστε να εντοπιστούν οι περιοχές της εικόνας που είναι πιο χρήσιμες για την παραγωγή της επόμενης λέξης.

Για τον υπολογισμό των τιμών προσοχής, οι έξοδοι του encoder και η κρυφή κατάσταση του αποκωδικοποιητή προβάλλονται σε έναν κοινό χώρο προσοχής μέσω γραμμικών μετασχηματισμών. Το άθροισμά τους περνάει από μια μη γραμμική συνάρτηση ενεργοποίησης (ReLU) και στη συνέχεια από έναν ακόμη γραμμικό μετασχηματισμό, που παράγει τις βαθμολογίες προσοχής. Οι βαθμολογίες αυτές κανονικοποιούνται με softmax, ώστε να αποτελούν πιθανότητες, υποδεικνύοντας τη σχετική σημασία κάθε περιοχής της εικόνας.

Το τελικό βήμα περιλαμβάνει τον υπολογισμό του context vector, όπου οι χωρικές εξόδους του encoder σταθμίζονται από τις τιμές προσοχής και αθροίζονται. Το διάνυσμα αυτό μεταφέρει στον αποκωδικοποιητή την πιο σχετική πληροφορία της εικόνας για την παραγωγή της επόμενης λέξης, ενισχύοντας την ακρίβεια και τη συνοχή των παραγόμενων περιγραφών.

Η ενσωμάτωση της προσοχής στο σύστημα βελτιώνει σημαντικά την απόδοσή του, καθώς επιτρέπει την παραγωγή λεζάντων προσαρμοσμένων στο περιεχόμενο κάθε εικόνας. Επιπλέον, οι τιμές προσοχής παρέχουν ερμηνευσιμότητα στο μοντέλο, υποδεικνύοντας ποια σημεία της εικόνας αξιοποιούνται σε κάθε χρονικό βήμα της λεζάντας.

Βαθιά Αναδρομικά Νευρωνικά Δίκτυα (LSTM decoder with Attention)

Ο αποκωδικοποιητής LSTMDecoderWithAttention αποτελεί τον βασικό μηχανισμό παραγωγής λεζάντας στο προτεινόμενο σύστημα αυτόματης περιγραφής εικόνας. Είναι υπεύθυνος για τη σταδιακή παραγωγή λέξεων, αποκωδικοποιώντας τα χαρακτηριστικά της εικόνας που προέρχονται από το encoder. Ο αποκωδικοποιητής αυτός ενσωματώνει μηχανισμό προσοχής, επιτρέποντας στο μοντέλο να εστιάζει δυναμικά σε διαφορετικές περιοχές της εικόνας κατά τη διάρκεια της διαδικασίας παραγωγής.

Η αρχιτεκτονική του βασίζεται σε ένα πολυεπίπεδο δίκτυο Long Short-Term Memory (LSTM), ειδικά διαμορφωμένο για να διαχειρίζεται τη σειριακή φύση της παραγωγής λεζάντας. Σε αντίθεση με κλασικούς LSTM αποκωδικοποιητές, ο συγκεκριμένος ενσωματώνει μηχανισμό προσοχής που επιτρέπει στο δίκτυο να επιλέγει κάθε φορά τα πιο σημαντικά χωρικά χαρακτηριστικά της εικόνας για την πρόβλεψη της επόμενης λέξης.

Οι είσοδοι του αποκωδικοποιητή περιλαμβάνουν: (1) τις χωρικές εξόδους του encoder με διαστάσεις (batch_size, num_pixels, encoder_dim), (2) τις κωδικοποιημένες λεζάντες σε μορφή ακολουθίας δεικτών λέξεων και (3) το μήκος κάθε λεζάντας, ώστε να καθορίζεται η διάρκεια αποκωδικοποίησης για κάθε δείγμα. Αρχικά, οι λέξεις μετατρέπονται σε πυκνές αναπαραστάσεις μέσω ενός embedding layer και συνενώνονται με το attention-weighted encoding, πριν εισαχθούν στο LSTM.

Ο μηχανισμός προσοχής υπολογίζει σε κάθε χρονικό βήμα ένα context vector, σταθμίζοντας τις χωρικές εξόδους του encoder με βάση τη σχετικότητά τους με την τρέχουσα κατάσταση αποκωδικοποίησης. Το διάνυσμα αυτό συνδυάζεται με την έξοδο του LSTM μέσω ενός gating μηχανισμού, ο οποίος ελέγχει τη συμβολή του context vector. Το gate υλοποιείται ως sigmoid ενεργοποίηση πάνω σε γραμμικό μετασχηματισμό της κρυφής κατάστασης του LSTM.

Σε κάθε χρονικό βήμα, ο αποκωδικοποιητής παράγει μια πιθανότητα κατανομής πάνω στο λεξιλόγιο για την πρόβλεψη της επόμενης λέξης, καθώς και τις αντίστοιχες τιμές προσοχής για τα σημεία της εικόνας. Επιπλέον, υποστηρίζει αρχικοποίηση των καταστάσεων του LSTM με βάση

το μέσο όρο των εξόδων του encoder, εξασφαλίζοντας καλύτερη μεταφορά πληροφορίας από την εικόνα προς τη διαδικασία παραγωγής.

Η χρήση του LSTM αποκωδικοποιητή με μηχανισμό προσοχής συμβάλλει καθοριστικά στη δημιουργία συνεκτικών και περιεχομενικά σχετικών λεζάντων. Η δυναμική ευθυγράμμιση περιοχών εικόνας και λέξεων εξασφαλίζει ότι το σύστημα παράγει λεζάντες που ανταποκρίνονται στο περιεχόμενο και τη σημασία των εικονικών χαρακτηριστικών, ενισχύοντας την αποτελεσματικότητα του συνδυασμού ακολουθιακών νευρωνικών δικτύων με attention σε εφαρμογές όρασης και γλώσσας.

Εκπαίδευση και Επικύρωση

Στο αρχείο `train.py` καθορίζονται οι κρίσιμες υπερπαράμετροι και διαδικασίες που ρυθμίζουν την εκπαίδευση του μοντέλου για την παραγωγή λεζάντων εικόνας. Η επιλογή των υπερπαραμέτρων βασίστηκε σε προηγούμενες σχετικές εργασίες στη βιβλιογραφία και σε αρχικές δοκιμές, με στόχο την ισορροπία μεταξύ υπολογιστικής απόδοσης και ποιότητας λεζάντας.

Ο χώρος των διαστάσεων του μοντέλου έχει ως εξής: `emb_dim = 512` για τις ενσωματώσεις λέξεων, ώστε να επιτρέπεται επαρκής χωρητικότητα αναπαράστασης του σημασιολογικού περιεχομένου. Ομοίως, η `attention_dim = 512` διασφαλίζει ότι οι χωρικές απεικονίσεις της εικόνας και οι κρυφές καταστάσεις του LSTM προβάλλονται σε κοινό χώρο προσοχής. Αντίστοιχα, το `decoder_dim = 300` επιλέχθηκε για τις κρυφές καταστάσεις του αποκωδικοποιητή LSTM, ως μια καλή ισορροπία ανάμεσα σε υπολογιστική πολυπλοκότητα και μοντελοποίηση ακολουθιών.

Για τη βελτιστοποίηση, χρησιμοποιούνται διακριτοί ρυθμοί εκμάθησης: `encoder_lr = 1e-4` για τον κωδικοποιητή ResNet34 και `decoder_lr = 5.1e-4` για τον αποκωδικοποιητή. Το υψηλότερο learning rate στον αποκωδικοποιητή επιτρέπει ταχύτερη προσαρμογή στην παραγωγή λεζάντας, ενώ ο encoder, ως προεκπαιδευμένο μοντέλο, μαθαίνει πιο συντηρητικά όταν ενεργοποιείται το fine-tuning. Το `dropout = 0.3` εφαρμόζεται στον αποκωδικοποιητή για αποφυγή υπερπροσαρμογής, ενώ το `grad_clip = 5.0` προστατεύει από την εμφάνιση exploding gradients, κάτι που είναι σύνηθες σε επαναληπτικά δίκτυα.

Ιδιαίτερη σημασία δίνεται στη ρύθμιση `alpha_c = 1.0`, που αφορά την κανονικοποίηση του μηχανισμού προσοχής. Η παράμετρος αυτή ενισχύει την απαίτηση το άθροισμα των attention weights σε όλα τα βήματα να προσεγγίζει τη μονάδα, διασφαλίζοντας ότι το μοντέλο εστιάζει ισόρροπα και όχι μονοσήμαντα σε συγκεκριμένα σημεία της εικόνας.

Η εκπαίδευση οργανώνεται με `batch_size = 32` και αριθμό εποχών epochs προσαρμόσιμο μέσω ορίσματος. Σε περίπτωση στασιμότητας στη βελτίωση του BLEU-4 score για 5 διαδοχικές εποχές, εφαρμόζεται μείωση του learning rate κατά 30% στον αποκωδικοποιητή και 20% στον κωδικοποιητή (όταν fine-tuning είναι ενεργό), με στόχο τη σταδιακή σταθεροποίηση της

εκμάθησης. Επιπλέον, ο μηχανισμός early stopping τερματίζει την εκπαίδευση αν δεν υπάρξει βελτίωση σε 20 εποχές, αποτρέποντας άσκοπες επαναλήψεις.

Τέλος, το σύστημα καταγράφει αναλυτικά μετρικές όπως οι BLEU scores, train/validation loss, και top-5 accuracy ανά εποχή. Οι τιμές αυτές αποθηκεύονται σε αρχεία JSON και checkpoints, επιτρέποντας την παρακολούθηση της πορείας εκπαίδευσης και την επιλογή του βέλτιστου μοντέλου. Ο σχεδιασμός αυτός εξασφαλίζει σταθερή σύγκλιση και ποιοτικά αποτελέσματα στην παραγωγή περιγραφών εικόνας.

Βαθιά Ενισχυτική Μάθηση

Για την υλοποίηση βαθιάς ενισχυτικής μάθησης για την παραγωγή περιγραφών εικόνας, αξιοποιήθηκε ο αλγόριθμος Advantage Actor-Critic (A2C). Το σύστημα συνδυάζει έναν CNN-βασισμένο κωδικοποιητή, έναν αποκωδικοποιητή LSTM με μηχανισμό προσοχής και ένα κριτήριο ανταμοιβής (critic network) για τη βελτιστοποίηση της ποιότητας των παραγόμενων λεζαντών. Η αρχιτεκτονική αυτή επιτρέπει στο μοντέλο να μαθαίνει να περιγράφει εικόνες με τρόπο που μεγιστοποιεί μετρικές αξιολόγησης, όπως οι BLEU scores.

Το μοντέλο αποτελείται από τρία βασικά υποσυστήματα: τον κωδικοποιητή (EncoderCNN), έναν αποκωδικοποιητή (Actor) που βασίζεται σε LSTM με μηχανισμό προσοχής, και το κριτήριο ανταμοιβής (Critic), το οποίο αξιολογεί την ποιότητα των παραγόμενων λεζαντών. Ο κωδικοποιητής χρησιμοποιεί προεκπαιδευμένο ResNet34 για την εξαγωγή χαρακτηριστικών εικόνας, ενώ ο αποκωδικοποιητής παράγει τις λεζάντες λέξη προς λέξη, καθοδηγούμενος από τις εξαγόμενες περιοχές ενδιαφέροντος. Για τον κριτή έγινε δοκιμή με δύο εκδοχές του, έναν MLP τριών layer, και έναν CNN δύο συνελεκτικών layer με ένα adaptive average pooling.

Η διαδικασία εκπαίδευσης ακολουθεί τη λογική του A2C, όπου σε κάθε βήμα υπολογίζονται οι λεζάντες, οι προβλέψεις του Critic, οι ανταμοιβές (μέσω BLEU scores) και τα πλεονεκτήματα (advantages). Ο υπολογισμός του loss γίνεται ξεχωριστά για τον Actor (με όρους ενθάρρυνσης εξερεύνησης μέσω entropy regularization) και τον Critic (μέσω μέσης τετραγωνικής απόκλισης). Οι βελτιώσεις των βαρών πραγματοποιούνται με ανεξάρτητους βελτιστοποιητές για κάθε υποσύστημα, επιτρέποντας ευέλικτο έλεγχο των ρυθμών μάθησης.

Κατά την επικύρωση, το σύστημα παράγει λεζάντες για σύνολα εικόνας και υπολογίζει τις BLEU-4 τιμές για τη σύγκριση με τις πραγματικές λεζάντες. Οι τιμές αυτές χρησιμοποιούνται για την αξιολόγηση της απόδοσης και την αποθήκευση του βέλτιστου μοντέλου. Επιπλέον, κατά τη διάρκεια της εκπαίδευσης εφαρμόζεται προσαρμογή ρυθμών μάθησης και βαρών entropy σε περίπτωση στασιμότητας.

Συνολικά, στο A2C.py ενσωματώνει μια προηγμένη προσέγγιση παραγωγής λεζαντών εικόνας που συνδυάζει τεχνικές ενισχυτικής και βαθιάς μάθησης. Η αξιοποίηση του μηχανισμού προσοχής και του υβριδικού κριτηρίου το καθιστούν ιδιαίτερα αποτελεσματικό για σύνθετα προβλήματα

κατανόησης και περιγραφής οπτικού περιεχομένου, ωστόσο λόγω της χρήσης αδύναμου κριτή, τα αποτελέσματα που έχουμε στο πέρας της εκπαίδευσης είναι λιγότερο ικανοποιητικά από αυτά του μοντέλου χωρίς την βαθιά ενισχυτική.

Παράμετροι και Υπερπαράμετροι Εκπαίδευσης

Το σύστημα Advantage Actor-Critic (A2C) που υλοποιήθηκε για το πρόβλημα της περιγραφής εικόνων βασίζεται σε ένα σύνολο κρίσιμων παραμέτρων και υπερπαραμέτρων οι οποίες ρυθμίζουν τη δυναμική της μάθησης και τη συμπεριφορά της εκπαίδευσης. Κεντρικές παράμετροι αποτελούν οι ρυθμοί μάθησης (learning rates) που αποδίδονται ξεχωριστά στον encoder, στον decoder (actor) και στο critic δίκτυο, οι οποίοι σημειώνονται ως `encoder_lr`, `decoder_lr` και `critic_lr` αντίστοιχα. Οι τιμές αυτές καθορίζονται με στόχο τη σταθερή σύγκλιση του αλγορίθμου, αποδίδοντας συνήθως ελαφρώς υψηλότερη τιμή στον decoder, λόγω του άμεσου ρόλου του στη δημιουργία ακολουθιών.

Για την αποτροπή πρόωρης σύγκλισης σε υποβέλτιστες πολιτικές, ενσωματώνεται στον υπολογισμό της απώλειας του actor ένας όρος εντροπίας, ο οποίος σταθμίζεται μέσω της υπερπαραμέτρου `entropy_weight`. Ο όρος αυτός προωθεί τη διερεύνηση (exploration) κατά τη διαδικασία επιλογής ενεργειών. Επιπλέον, η υπερπαράμετρος `value_loss_weight` χρησιμοποιείται για να σταθμίσει τη συμβολή της απώλειας του critic στην ολική απώλεια, επιτυγχάνοντας ισορροπία ανάμεσα στη βελτίωση της πολιτικής και την εκτίμηση της τιμής (value estimation).

Το πρόβλημα απόδοσης πίστωσης στον χρόνο (temporal credit assignment) αντιμετωπίζεται μέσω της εισαγωγής του παράγοντα έκπτωσης `gamma`, ο οποίος ρυθμίζει το βάρος των μελλοντικών ανταμοιβών στη συνολική επιστροφή. Υψηλές τιμές (π.χ. 0.99) δίνουν έμφαση σε αποτελέσματα που προκύπτουν σε μεγαλύτερο χρονικό ορίζοντα. Για την αποφυγή φαινομένων εκρηκτικής αύξησης των παραγώγων (gradient explosion), εφαρμόζεται τεχνική αποκοπής παραγώγων (gradient clipping) με όριο `max_grad_norm`. Συμπληρωματικά, παράμετροι όπως το `beam_size` για τον έλεγχο του beam search και η `temperature` για τη ρύθμιση της ισορροπίας εξερεύνησης–εκμετάλλευσης κατά τη δειγματοληψία, συμβάλλουν στη συνολική σταθερότητα και αποτελεσματικότητα του αλγορίθμου. Τέλος, η παράμετρος `reward_scale` κλιμακώνει τις ανταμοιβές που προκύπτουν από τις BLEU τιμές, εξασφαλίζοντας αριθμητικά σταθερές ενημερώσεις.

Ορισμός και Υπολογισμός Ανταμοιβής

Στο συγκεκριμένο σύστημα, η ανταμοιβή ορίζεται με βάση τις τιμές BLEU, οι οποίες αποτελούν καθιερωμένο μέτρο απόδοσης στον τομέα της Επεξεργασίας Φυσικής Γλώσσας για την αξιολόγηση παραγόμενων λεζαντών σε σχέση με τις αντίστοιχες αναμενόμενες περιγραφές. Συγκεκριμένα, η λεζάντα που δημιουργείται για κάθε εικόνα συγκρίνεται με μία ή περισσότερες

αναφορές, υπολογίζοντας τις τιμές BLEU-1, BLEU-2 και BLEU-4. Στη συνέχεια, οι τιμές αυτές συνδυάζονται σε μια ενιαία τιμή ανταμοιβής μέσω γραμμικού συνδυασμού, αποδίδοντας βάρη 20%, 30% και 50% στις BLEU-1, BLEU-2 και BLEU-4 αντίστοιχα.

Η σύνθετη αυτή ανταμοιβή ενσωματώνει τόσο την απλή λεξική σύμπτωση (unigram) όσο και συμφοραζόμενα μεγαλύτερου μήκους (n-gram), αντανακλώντας την ευστοχία και τη γλωσσική συνέπεια της παραγόμενης περιγραφής. Η προκύπτουσα τιμή ανταμοιβής προσαρμόζεται περαιτέρω μέσω της παραμέτρου `reward_scale`, διασφαλίζοντας τη βέλτιστη αριθμητική συμπεριφορά της διαδικασίας εκπαίδευσης. Τέλος, υπολογίζονται προεξοφλημένες επιστροφές (discounted returns) για κάθε χρονική στιγμή με βάση την τιμή αυτή, χρησιμοποιώντας τον συντελεστή έκπτωσης `gamma`. Οι επιστροφές αυτές αξιοποιούνται για την εκτίμηση πλεονεκτήματος (advantage estimation) και για την εκπαίδευση του critic.

Συναρτήσεις Απώλειας Actor και Critic

Η συνολική συνάρτηση απώλειας του A2C πλαισίου αποτελείται από δύο βασικά σκέλη: την απώλεια του actor και την απώλεια του critic. Η απώλεια του actor υπολογίζεται ως το αρνητικό γινόμενο της λογαριθμικής πιθανότητας της επιλεγμένης ενέργειας με την αντίστοιχη εκτίμηση πλεονεκτήματος. Η συνάρτηση ενσωματώνει επιπλέον έναν όρο εντροπίας, σταθμισμένο μέσω της παραμέτρου `entropy_weight`, ο οποίος ενθαρρύνει την εξερεύνηση αποτρέποντας την ταχεία σύγκλιση σε ντετερμινιστικές πολιτικές. Μαθηματικά αποδίδεται ως:

$$L_{actor} = -E[\log \pi(a_t/s_t) * A_t] - \beta * E[H(\pi)]$$

Αντίστοιχα, η απώλεια του critic ποσοτικοποιεί το σφάλμα εκτίμησης της τιμής κατάστασης, μέσω της μέσης τετραγωνικής απόκλισης (MSE) μεταξύ των προβλεπόμενων τιμών και των πραγματικών επιστροφών:

$$L_{critic} = E[(R_t - V(s_t))^2]$$

Η συνολική απώλεια προκύπτει ως σταθμισμένο άθροισμα των δύο:

$$L_{total} = L_{actor} + value_loss_weight * L_{critic}$$


και μέσω αυτής πραγματοποιείται η ενημέρωση των παραμέτρων σε όλα τα δίκτυα, ολοκληρώνοντας κάθε κύκλο εκμάθησης.

Αποτελέσματα και συζήτηση

Αρχικά θα παρουσιαστούν τα αποτελέσματα από την εκπαίδευση στο σετ Flickr8k. Κατά μέσο όρο ο χρόνος η εκπαίδευσης στα σετ δεδομένων αυτά ήταν περίπου στις 4μίση με 6 ώρες. Έγιναν 2 δοκιμές στο του μοντέλου στο σετ αυτό. Μία με την χρήση του word map όπως αυτή δημιουργήθηκε στην προετοιμασία των δεδομένων και μία με εφαρμογή One-hot-encoding. Για

την πρώτη, τα Blue-4 σκορ που καταγράφτηκαν ποικίλουν για διαφορετικά beam sizes. Αυτό προκύπτει διότι η αναζήτηση beam χρησιμοποιείται για τη δημιουργία λεζάντων με την παρακολούθηση των κορυφαίων k (μέγεθος δέσμης) πιο πιθανών ακολουθιών σε κάθε βήμα αποκωδικοποίησης. Όσο μεγαλύτερο είναι το μέγεθος της δέσμης, τόσο περισσότερες υποψήφιες ακολουθίες εξετάζονται, γεγονός που αυξάνει την πιθανότητα δημιουργίας μιας υψηλής ποιότητας λεζάντας. Ωστόσο, αυτό δεν εγγυάται πάντα καλύτερα αποτελέσματα λόγω περιορισμών όπως η υπερβολική προσαρμογή σε ακολουθίες υψηλής πιθανότητας. Τα blue4 σκορ λοιπόν στο σετ ελέγχου για τα δέσμη beam 1, 3, και 5 ήταν 0.1333, 0.1525 και 0.1558 αντίστοιχα, με ελάχιστα καλύτερο να είναι το τελευταίο.

Στο γράφημα φαίνονται τα στατιστικά κατά την εκπαίδευση και επικύρωση του μοντέλου.



Παρακάτω παρουσιάζονται τα αποτελέσματα του μοντέλου σε μερικές τυχαίες φωνογραφίες από το διαδίκτυο.

Generated: a brown and white dog is jumping in the air




Generated: a brown dog is looking at the camera







Generated: a man in a blue shirt is walking down a sidewalk





Η εκπαίδευση του μοντέλου χρησιμοποιώντας One-hot-encoding λόγω της sparse αναπαράστασης που δημιουργεί για το σύνολο των λέξεων, καθιστά σχεδόν άχρηστη την χρήση την αναζήτησης ακτίνας (beam). Η βασικές διαφορές που παρατηρήθηκαν σε σχέση με την προηγούμενη υλοποίηση ήταν ο χρόνος που ήταν κάπως μικρότερος, γύρω στις 4 ώρες η εκπαίδευση και ενώ η το Blue-4 σκορ που κατέγραψε στο σετ ελέγχου ήταν σχεδόν πανομοιότυπο για όλα τα μεγέθη αναζήτησε beam και αυτό να είναι 0.1455.




Generated: a brown dog is running in the grass



Generated: a brown and white dog is on a bed





Όσο αφορά το μεγαλύτερο σετ δεδομένων Flickr30k. Εδώ δεν εφαρμόστηκε έλεγχος απόδοσης με την διαφορά στην κωδικοποίηση one-hot ή όχι λόγο του μεγέθους και του χρόνου στην εκπαίδευση. Αρχικά η βασική διαφορά ήταν όσο αφορά τον χρόνο. Για batch size 64 το μοντέλο εκπαιδευόταν για περίπου 9 ώρες και έφτασε μέχρι την 7 εποχή. Τα σκορ που κατέγραψε στο σετ δοκιμής ήταν 0.1734 για ακτίνα beam 5. Ωστόσο λόγο του όγκου των δεδομένων, δεν είναι σε θέσει αν δημιουργήσει ικανοποιητικές λεζάντες:

Generated: a dog is running through the snow



Generated: a young girl in a pink shirt is sitting in a chair



Μειώνοντας τον μέγεθος των baches από 64 σε 32 βλέπουμε βελτίωση στον χρόνο όπου στο ίδιο χρονικό διάστημα, δηλαδή 9 ώρες καταφέρνει να τρέξει για 29 εποχές. Τα σκορ που επιτυγχάνονται είναι 0.1671 και 0.1672 για μέγεθος ακτίνας 3 και 5 αντίστοιχα. Και πάλι οι λεζάντες που δημιουργούνται από το μοντέλο δεν είναι καθόλου ικανοποιητικές, με μερικές ενδεικτικές από αυτές να είναι:

Generated: a brown dog is running through a tunnel





Generated: a woman in a pink shirt is holding a red cup





Τέλος για την εκπαίδευση με χρήση βαθιάς ενισχυτικής μάθησης. Εδώ το μοντέλο έτρεξε για πολύ περισσότερο χρόνο, στο σετ Flickr8k. Ο λόγος που εκτελέστηκε η εκπαίδευση για μία φορά ήταν,

ο μεγάλος χρόνος εκπαίδευσης για μία εποχή, καθώς και η φύση της μάθησης αυτής που λόγο της εξερεύνησης δεν γίνεται να έχουμε καλά αποτελέσματα γρήγορα ορατά. Ο advanced actor critic με τον MLP κριτή λοιπόν εκτελέστηκε για 176 εποχές με χρόνο εκπαίδευσης περίπου μία μέρα. Τα στατιστικά της εκπαίδευσης του είναι τα ακόλουθα. Στις εικόνες φαίνεται η ξεκάθαρη αδυναμία του μοντέλου και κυρίως η έλλειψη του καλού κριτή καθώς βλέπουμε ότι ενώ ο actor δοκιμάζει πράγματα και βελτιώνεται ο κριτής μένει σταθερά στο 0, με ελάχιστες φορές καθόλη την εκπαίδευση να το υπερβαίνει για πολύ λίγο.



Τέλος, ο advanced actor critic με τον MLP κριτή λοιπόν εκτελέστηκε για 200 εποχές με χρόνο εκπαίδευσης περίπου πάνω από μία μέρα. Τα στατιστικά της εκπαίδευσης του είναι τα ακόλουθα.



Αν και αυτή η προσέγγιση αξιοποιεί συνελκτικά στρώματα για την αποτύπωση χωρικών χαρακτηριστικών από τα embeddings της εικόνας, η καμπύλη εκπαίδευσης δείχνει σημαντική αστάθεια στο Actor Loss, με απότομη αύξηση στην αρχή και αργή σύγκλιση σε σχέση με τη δεύτερη περίπτωση. Αυτό υποδεικνύει ότι η πρόσθετη πολυπλοκότητα του CNN κριτή μπορεί να προκαλεί πιο θορυβώδεις ή λιγότερο αξιόπιστες εκτιμήσεις τιμής κατά τις ενημερώσεις της πολιτικής. Αντίθετα, ο απλούστερος MLP-based κριτής προσφέρει πιο ομαλή και σταθερή μαθησιακή συμπεριφορά, δείχνοντας ότι για αυτό το πρόβλημα, μια πιο λιτή αρχιτεκτονική κριτή είναι πιο αποδοτική στη βελτιστοποίηση της πολιτικής.

Συμπεράσματα και προτάσεις

Βάση της απόδοσης του μοντέλου στα διαφορετικά σεν δοκιμών και συγκρίνοντάς την με τις καταγεγραμμένες επιδόσεις, παρατηρείται ότι το μοντέλο παρουσιάζει λογική έως μέτρια απόδοση. Τα προβλήματα και οι περιορισμοί που εντοπίζονται προκύπτουν κυρίως από δύο βασικούς παράγοντες: αφενός, την έλλειψη εμπειρίας και την εσφαλμένη επιλογή παραμέτρων σε ορισμένες περιπτώσεις, και αφετέρου, την απουσία κατάλληλου υπολογιστικού εξοπλισμού.

Η έλλειψη εμπειρίας έγινε εμφανής κυρίως στη δυσκολία σύνδεσης του CNN encoder με τον LSTM decoder και το Attention Network, καθώς και στη δημιουργία των δύο τελευταίων, δεδομένου ότι η σχετική βιβλιογραφία δεν ήταν το ίδιο υποστηρικτική σε σύγκριση με αυτή της ResNet. Το δεύτερο και σημαντικότερο πρόβλημα ήταν η περιορισμένη διαθεσιμότητα ισχυρού hardware για την εκτέλεση, εκπαίδευση και επικύρωση των διάφορων εκδοχών του μοντέλου μέχρι την τελική του μορφή. Η έλλειψη αυτή, σε συνδυασμό με το υψηλό κόστος λαθών, οδήγησε συχνά στη διακοπή της εκπαίδευσης, ώστε να αποφευχθεί πιθανή βλάβη στον υπολογιστή.

Τα συμπεράσματα για το διαθέσιμο υλικό έχουν ως εξής: Το περιορισμένο λεξιλόγιο, το οποίο δημιουργήθηκε από τις λέξεις που υπήρχαν στις λεζάντες εκπαίδευσης, έθεσε ουσιαστικά ένα όριο στα σκορ ακρίβειας που μπορούσαν να επιτευχθούν. Αυτό έγινε ιδιαίτερα εμφανές στην εκπαίδευση με το μεγαλύτερο dataset, το Flickr30k, όπου, παρότι οι λεζάντες που παρήγαγε το μοντέλο ήταν ποιοτικά κατώτερες, τα σκορ ακρίβειας εμφανίστηκαν ελαφρώς βελτιωμένα. Ενδεικτικά, το λεξιλόγιο του μικρού σεν περιλάμβανε 2.600 λέξεις, ενώ του μεγάλου 7.000.

Επιπλέον, η σύγκριση της χρήσης word embeddings (wordmap) έναντι του one-hot encoding έδωσε αναμενόμενα αποτελέσματα: παρόλο που με το one-hot encoding η εκπαίδευση ήταν ταχύτερη, η χρήση του Attention Network και της τεχνικής beam search καθίστατο ουσιαστικά άχρηστη. Ο λόγος είναι ότι το beam search δημιουργεί ακολουθίες λέξεων φυσικής γλώσσας, επιλέγοντας κάθε φορά από τις k πιθανότερες λέξεις για κάθε βήμα του attention. Με το one-hot encoding, όμως, οι σημασιολογικά κοντινές λέξεις δεν έχουν παρόμοια διανύσματα, αλλά μοναδιαία διανύσματα μεγέθους ίσου με το λεξιλόγιο, κάτι που εμποδίζει τη σωστή λειτουργία της δέσμης αναζήτησης.

Όσον αφορά το μέγεθος των batch στην εκπαίδευση, διαπιστώθηκε ότι μεγαλύτερα batch βελτίωναν την απόδοση του μοντέλου, αλλά ταυτόχρονα αύξαναν σημαντικά το υπολογιστικό κόστος, με αποτέλεσμα η εκπαίδευση να μην είναι εφικτή υπό τις διαθέσιμες συνθήκες.

Τέλος, η περαιτέρω εκπαίδευση με τη χρήση βαθιάς ενισχυτικής μάθησης έδειξε ενδιαφέροντα αποτελέσματα. Αρχικά, λόγω της γενικευμένης πολιτικής που ακολουθεί το μοντέλο στα πρώτα στάδια, δυσκολεύεται να συγκεντρώσει θετικά reward, ακόμη και αν έχει προεκπαιδευτεί στο ίδιο dataset. Επιπλέον, η απουσία αποτελεσματικού κριτή περιέπλεξε τη διαδικασία μάθησης, καθώς τα reward που παρείχε για τη βελτίωση των gradients του μοντέλου δεν ήταν κατάλληλα. Ιδανικά, θα θέλαμε ο κριτής να κάνει λάθη στην αρχή, αλλά σταδιακά να σταθεροποιείται, διατηρώντας μια συνεπή πορεία στο loss, κάτι που δεν συνέβη στην παρούσα περίπτωση. Παρ' όλα αυτά, το

μοντέλο άρχισε να βελτιώνεται — από το να παίρνει αρχικά τυχαίες και λανθασμένες αποφάσεις, προχώρησε σε βελτίωση των επιδόσεών του, αυξάνοντας την ανταμοιβή που δεχόταν. Με έναν πιο αποδοτικό κριτή και περισσότερο χρόνο εκπαίδευσης, είναι πιθανό να μπορούσαν να επιτευχθούν αξιόλογα αποτελέσματα και σε αυτό το κομμάτι.

Συγκρίνοντας την υλοποίηση του A2C με έναν υβριδικό κριτή παρατηρείτε μεγαλύτερη αστάθεια σε σχέση με την πρώτη υλοποίηση του MLP κριτή. Ο υβριδικός CNN κριτής εμφανίζει μεγαλύτερη αστάθεια σε σχέση με τον απλό MLP κριτή, κυρίως λόγω της αυξημένης πολυπλοκότητας και του μεγαλύτερου αριθμού παραμέτρων. Η επιπλέον αυτή πολυπλοκότητα τον καθιστά πιο ευαίσθητο σε θορυβώδη ή υψηλής διακύμανσης σήματα ανταμοιβής, που είναι σύνηθες φαινόμενο στη μάθηση ενίσχυσης. Επιπλέον, το CNN μπορεί να υπερεκτιμήσει ασήμαντα χωρικά μοτίβα από τα embeddings των εικόνων, οδηγώντας σε μη σταθερές και αναξιόπιστες εκτιμήσεις τιμής. Αντίθετα, ο απλούστερος MLP κριτής συγκλίνει πιο γρήγορα και παρέχει πιο σταθερά και χαμηλής διακύμανσης αποτελέσματα, ευνοώντας σταθερότερες ενημερώσεις της πολιτικής.

Ο αναλυτικός κώδικας της εργασίας βρίσκεται στην αρχή του αρχείου και περιλαμβάνει όλα τα διαθέσιμα tests, scripts και οδηγίες για την εκτέλεσή τους.